

# POLISH DATA ANONYMIZATION

Fine-tuned HerBERT NER model  
for 25 sensitive classes.

- 25 Klas (RODO)
- Brak zewnętrznych API
- 100% Offline
- Wykorzystanie HerBER

## What is Data Anonymization?



# DANE I PRZYGOTOWANIE

## ŽRÓDŁO I FORMAT

Wejście: `orig.txt` (raw) + `anonymized.txt` (gold).

Konwersja: `convert_original_data.py` → CoNLL.

Zakres: 25 klas wrażliwych (PESEL, adres, imię, itp.).

## PRZETWARZANIE

Tokenizer: HuggingFace (HerBERT).

Split: Train / Dev / Test.

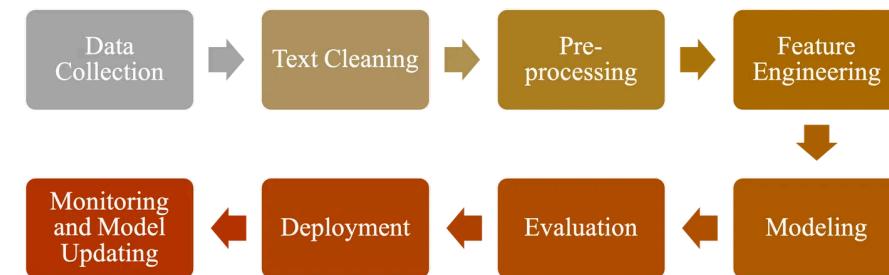
Max Length: 256 (trening), 512 (inference).

## CEL

Przygotowanie danych treningowych dla modeli PL (PLLuM).

Zachowanie struktury gramatycznej i sensu.

## NLP Pipeline



# MODEL I TRENING

## MODEL BAZOWY

**allegro/herbert-base-cased**

Polski BERT zoptymalizowany językowo.

## FINE-TUNING NER

**BIO Tagging Scheme**

51 etykiet (B-/I- dla 25 klas + O).

## PROCES TRENINGOWY

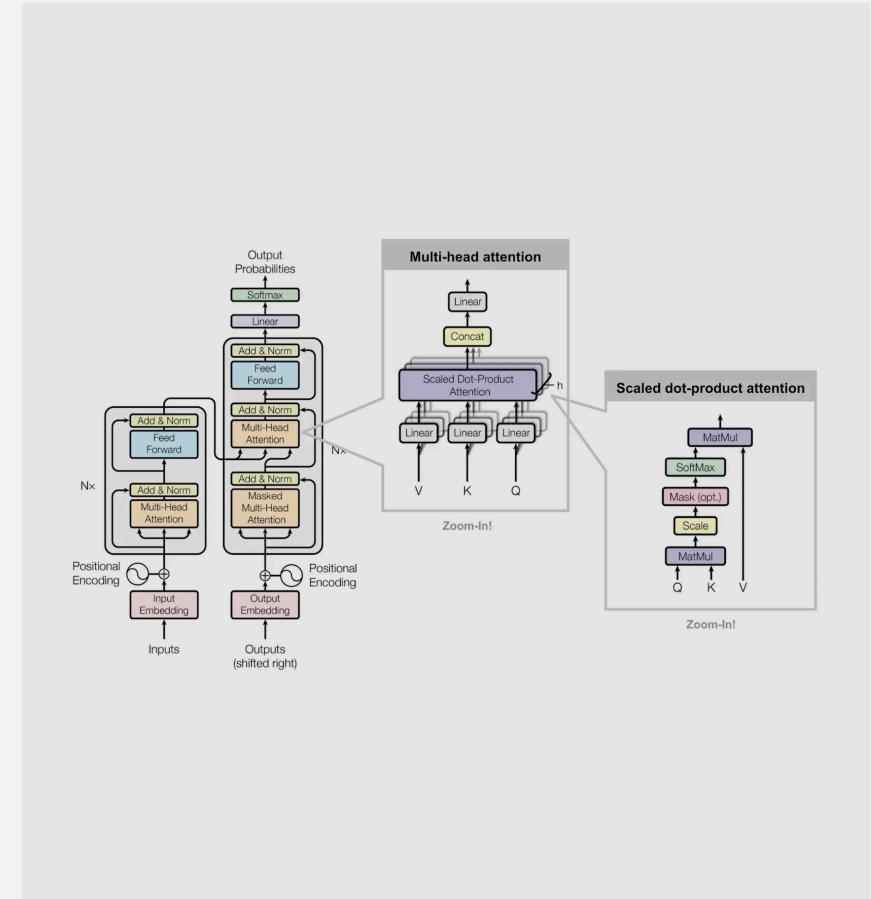
**Seqeval F1 Metric**

Skrypt: `train_herbert_ner.py train`

## CHECKPOINTING

**Best Model Saving**

Lokalny zapis: `model_output_finetuned/`



# INFERENCJA I EWALUACJA

## PIPELINE INFERENCYJNY

```
train_herbert_ner.py predict --input orig.txt
```

- 1 **Tokenizacja:** Podział na subtokeny HerBERT.
- 2 **Predykcja:** Model przewiduje tagi BIO.
- 3 **Offset Mapping:** Mapowanie na znaki oryginału.
- 4 **Scalanie:** Łączenie encji (B- + I-).
- 5 **Anonimizacja:** Wstawienie tagów [PESEL].

## METRYKI JAKOŚCI

```
evaluate_anonymization.py --gold anonymized.txt
```

### PRECISION

Dokładność detekcji  
(TP/TP+FP)

### RECALL

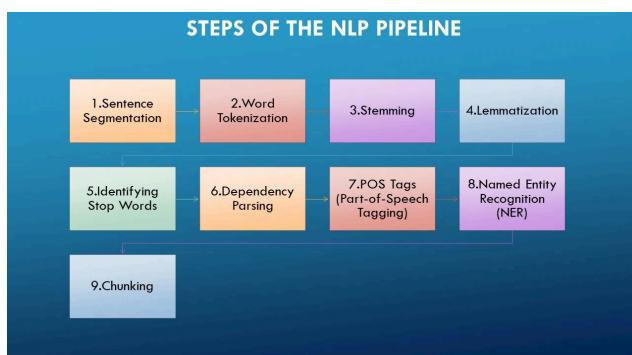
Pokrycie encji (TP/TP+FN)

### F1 SCORE

Średnia harmoniczna  
(Micro/Macro)

### PERFECT LINES

Liczba w pełni poprawnych  
zdań



**Output:** Raport CSV + Log błędów.

**Hardware:** Auto-detect CUDA / MPS / CPU.